

传染病预测视界的机制基准与实证校准差距

摘要：【目的】重大呼吸道传染病的前瞻预测在传播阈值临界点及多周外推中常出现技能骤降与区间欠覆盖。本文旨在厘清理论机制方差、现实预测误差与系统校准差距三者的数理关联，构建统摄微观接触、宏观更新与外部枢纽审计的预测视界基准体系。【方法】在信息流可测类上证明平方损失下的条件风险恒等式，确立条件均值预测器所达到的锐条件方差下界；推导固定离散度宏观负二项（NB2）递推更新模型的精确有限步方差闭式，刻画对数正态参数外推的非线性放大律；依托包含微观接触链（香港新冠与几内亚埃博拉）、全美 51 个州级多病原住院面板及美国 CDC FluSight 连续三赛季（2023–2026）官方版本化外部审计，开展严格四方共同单元配对评价。【结果】宏观方差闭式在数值模拟中完全自治（相对偏差 0.5%–1.5%）；微观数据强支持负二项设定（ ΔAIC 达 93.9–244.0）；51 州面板上 5 周基准窗口下代入式 NB2 机制视界跨州中位数为 2.2–7.1 周（多窗口极值包络 1.52–8.07 周）；三项描述性误差记账表明 21 个配置中跨州中位数代数差额占比中位数为 55.0%（20/21 为正），机制方差不足以包络实测误差。CDC FluSight 外部审计证实机制基准在终报条件下仍表现出显著欠覆盖（标称 95% 区间实测覆盖率仅 0.405–0.554），全周期事后分层更揭示疫情峰前期各模型经验覆盖率普遍骤降（2025–26 赛季机制预测器降至 0.140，全三季为 0.140–0.852；峰后期恢复至 0.925–0.964）。【结论】机制视界本质上是依赖工作模型与信息集的条件机制基准，在同口径下构成现实预警时效的宽松经验参考外包络。这一基准为公共卫生应急调度设定了统计可信窗口，并提示预测系统亟须攻关峰前期的动态方差膨胀与数据回填校准。

关键词：传染病预测；预测视界；更新模型；分支过程；机制基准；校准差距；加权区间评分

0 引言

0.1 研究背景与现实困境

重大呼吸道传染病（如新型冠状病毒感染、季节性流感与呼吸道合胞病毒 RSV）的周期性暴发对全球公共卫生与医疗体系构成长期挑战。在疫情早期的动态演化中，及时可靠的前瞻预测是优化重症资源配置、预置抗病毒药物与启动非药物干预（NPI）的关键支撑。然而，传染病前瞻预测在实务中频繁遭遇系统性失效瓶颈：当疫情处于平稳指数增长或下降阶段时，现有统计与动力学模型通常能保持较高准确度；但一旦逼近流行阈值（即基本再生数 $R \approx 1$ 的临界点）或开展多周前瞻外推，预测系统的性能便发生系统性劣化：预测区间急剧发散、预测轨迹频繁出现预测性能骤降与严重失准 [1]。Scarpino 与 Petri [2] 基于信息论与排列熵刻画了疫情在流行阈值附近的无模型内在可预测性突变；然而，无模型排列熵界主要反映时间序列本身的统计可压缩性，未显式给出特定生成机制下有限步前瞻方差的累积律与参数推断误差的传播闭式。

为应对前瞻预测的重大现实需求，计算流行病学形成了动力学房室模型、统计更新模型、机器学习与多模型集成四大范式。然而，跨越多年与多病种的大规模协同预测评估揭示了长期制约前瞻预测实践的结构性瓶颈。无论是美国 CDC FluSight 流感预测 [3, 4]、RAPIDD 埃博拉评估 [5]、登革热预测挑战 [6]，还是欧美 COVID-19 预测枢纽 [7, 8]，评估结果均表明：在多周前瞻外推（3–4 周及以上）或波次起伏临界期，绝大多数复杂流行病学模型的实测预测技巧均迅速衰减，甚至难以稳定优于简单的持续性基线或局部线性外推模型 [9, 10]。此外，早期监测数据普遍存在的报告延迟与漏报回填，使得远期外推面临严重的使用不可识别性 [11, 12]。

0.2 本文核心贡献与证据体系

针对上述理论空白与现实困境，本文构建了一套统摄理论机制方差、现实预测误差与系统校准差距的分层基准体系，核心贡献体现为：

1. **理论机制层面**：在信息集 $\mathcal{F}_t$ 的二次可积类上证明平方损失下的条件风险恒等式（定理 1），确立条件均值预测器达到的锐条件方差下界；推导固定离散度 k_{agg} 宏观负二项更新模型的精确有限步方差闭式（定理 2），刻画对数正态参数外推的非线性放大律与代入式预测器的超额风险（引理 3）。
2. **跨尺度实证层面**：在微观接触追踪队列上证实负二项过度离散的相对拟合优势（ ΔAIC 达 93.9–244.0）；在覆盖全美最多 51 个州级辖区的多病原住院面板上，测得 5 周基准窗口下代入式 NB2 机制视界跨州中位数为 2.2–7.1 周（多窗口包络 1.52–8.07 周）；描述性误差记账表明 21 个配置中跨州中位数代数差额占比中位数为 55.0%（20 个为正），证实机制方差不足以包络实测误差。
3. **外部枢纽审计层面**：全面接入 CDC FluSight 连续三个锁定历史赛季（2023–2026，共 204 个固化输入文件，SHA-256 逐文件核验固化）。实测揭示机制基准在终报条件下仍存在显著欠覆盖（标称 95% 区间实测覆盖率仅 0.405–0.554，区间显著收窄 12.6%–44.6%）；事后识别的全局峰值相对位置分层更发现各模型在峰前期普遍面临经验覆盖率骤降（Hub 集成降至 0.419–0.852，机制预测器仅 0.140–0.385；峰后期恢复至 0.925–0.964）。

为确保学术推论的严谨性，表 1 系统确立了全文学理主张的证据层级与方法学适用边界。全文学术用语均在此层级规范下严格使用。本文理论机制视界严格定义为“固定 NB2 工作模型与特定推断规则下的条件机制基准”，在同口径下构成现实业务时效的宽松经验参考外包络，而非不可逾越的绝对理论上限。

表 1：本文证据体系与方法学适用边界界定表

证据层级	关键数理 / 实证结果	严格支持的科学推论	适用边界与解释限制
理论下界层 ：条件风险恒等式（定理 1）	任意 $\mathcal{F}_t$ -可测规则在平方损失下的条件风险正交分解： $\mathcal{R}_h(\delta_h \mathcal{F}_t) = V_h + (m_h - \delta_h)^2$	条件均值唯一达到给定概率模型与信息集下的平方风险下界；预测视界进一步依赖预测规则、归一化与容忍阈值	条件方差 V_h 刻画模型与信息集内的不可约方差极限，不直接等同于现实复杂传播系统的内在理论下界；现实预测器亦不保证自动逼近
微观分支层 ：饱和极限与模型有效性（引理 2）	负二项 GW 分支过程内在相对方差饱和于 CV_∞^2 ；三组权威传播链负二项 AIC 显著优于 Poisson ($\Delta\text{AIC} = 93.9\text{--}244.0$)	确立了个体级超级传播过度离散的相对拟合优势；证实特定负二项似然下极大似然估计具备自治性	反映个体接触网络的随机性，不直接等同于宏观周度聚合序列；负二项属于相对优选模型，非排他机制
宏观更新层 ：固定参数 NB2 模型内方差（定理 2）	周度宏观负二项聚合更新工作模型的精确有限步方差闭式，含 $[(1 + 1/k_{\text{agg}})^h - 1]$ 几何发散主项	在给定 NB2 宏观生成过程与固定 k_{agg} 条件下，解析刻画了宏观过程离散度随步长的递推演化	几何累积项特定于固定 k_{agg} 的 NB2 结构；Poisson 或 NB1 设定下超临界相对方差呈有界饱和，状态空间模型亦受记忆约束
参数外推层 ：对数正态放大与信息界（引理 3、定理 3）	对数正态参数估计误差经指数外推导致的超额均方误差闭式 $P_{\text{exact}}(h)$ ；单代极大似然 Fisher 信息量与 Cramér–Rao 界	量化代入式点估计预测器在参数不确定性下的超额风险；确立理想无偏估计下的参数识别样本量阶数 $O(\varepsilon^{-2})$	参数放大项针对点估计代入式外推，不替代完整贝叶斯后验积分；理想 CRB 样本量未计入现实漏报与回填噪声
州级实证层 ：机制视界与误差记账（第 4 节）	51 个州级辖区面板测得代入式 NB2 机制视界中位数为 2.2–7.1 周；21 个配置中跨州代数差额占比中位数为 55.0%（ $h = 1$ 为 45.4%）	显式机制分量在多数配置中不能充分覆盖实测误差；机制视界在同口径下构成现实业务预警时效的宽松经验参考外包络	代数差额反映描述性构成，非因果正交分解；机制视界受推断窗口选择影响（5–10 周变动 $-48.7\% \sim +44.6\%$ ，包络 1.52–8.07 周）
外部审计层 ：CDC FluSight 外部审计（第 5 节）	连续三赛季严格四方共同单元审计证实 Hub 集成持续优于基线；代入式机制预测器严重欠覆盖（0.405–0.554）；峰前期覆盖率显著下降	量化了受控机制预测器与业务预测系统的经验评分及校准差距；为多模型在峰前期出现覆盖率下降提供了描述性实证线索	峰前期覆盖率下降混杂了结构变点、行为适应与回填等多重现实因素；机制预测器享有终报数据质量优势，属于受控诊断基准

1 研究回顾

面对前瞻预测精度的急剧衰退，现有文献主要沿三条脉络探索其内在机制与可预测性边界：

第一，随机分支过程与概率更新推断。Galton–Watson 负二项分支过程 [13] 与更新方程

为刻画个体超扩散提供了经典的统计似然基础 [14]。在群体推断层面，Cori 等 [15] 与 Gostic 等 [16] 确立了时变再生数 R_t 的贝叶斯滤波推断规范；Parag 等 [17–19] 进一步从信息论视角揭示了发病曲线反演再生数所固有的代间隔检测延迟与信息瓶颈。关于更新过程的方差演化与过度离散建模，自回归与负二项监测体系可追溯至 Held 等 [20] 及早期分支过程方差递推（如 Drake [21]）。然而，经典文献对多步前瞻条件方差多依赖递推数值卷积或蒙特卡洛仿真。本文在此脉络上推进，聚焦于离散周度尺度的固定离散度 NB2 宏观更新模型，通过对代间隔递推关系实施裂项求和，首次解析推导了任意有限提前期 h 的精确方差闭式解（定理 2），并由此逆解出机制预测视界的解析求根方程。

第二，生态预测视界与业务预测时效界定。在理论生态学领域，Petchey 等 [22] 将“生态预测视界”（Ecological Forecast Horizon）形式化定义为预测误差首次达到预设容忍度门槛的时间距离，并强调视界是依赖系统内在动力学、外生扰动、模型规则与损失函数的操作系统构造。近期，Wesselkamp 等 [23] 重新审视了生态预测极限，指出确定性非线性系统与随机生灭过程的可预测时间尺度上存在本质差异。针对流行病领域，Bozzuto 与 Ives [24] 在全美州县级尺度测算了 COVID-19 的模型无关时间序列可预测视界（约 8–9 周），发现宏观聚集与防控措施显著改变了可预测性空间分布。此外，Penn 等 [25] 明确区分了模型内在随机性与统计认知不确定性，本文在此理论基础之上推进了具体的方差闭式求解与视界解析反演。

第三，预测区间多维度评估与校准骤降。以加权区间评分（WIS）与概率积分变换（PIT）为代表的严格适当评分规则（Proper Scoring Rules）已成为衡量概率预测质量的核心准则 [26]。在多赛季流感与新冠预测的实证评估中，研究人员反复观察到预测模型在流行上升期出现覆盖率骤降与区间系统性偏窄的“校准骤降”现象 [3, 4, 7]。然而，现有实证评估多局限于对业务参赛模型的经验外推对比，缺乏一套剥离外生工程修饰的受控机制基准，因而难以厘清经验校准差距中有多少源于内在传播动力学机制方差，有多少源于数据报告延迟与行为非平稳漂移。本文通过构建受控代入式机制基准，首次填补了这一理论机制与业务审计之间的实证量化缺口。

2 传播动力学可预测视界理论

2.1 锐条件平方风险下界与尺度隔离原则

考虑离散时间下的周度宏观发病与住院监测序列 $\{Z_t\}_{t \geq 0}$ 。预测原点 t 历史信息集构成 σ -代数流 $\mathcal{F}_t = \sigma(Z_0, Z_1, \dots, Z_t; \mathbf{X}_t)$ 。预测目标为超前提前期 $h \geq 1$ 步的真实状态变量 Y_{t+h} （终报口径下 $Y_{t+h} = Z_{t+h}$ ）。定义预测规则类为 $\mathcal{D}_t \equiv L^2(\Omega, \mathcal{F}_t, \mathbb{P})$ 。记条件期望与条件方差分别为：

$$m_h \equiv \mathbb{E}[Y_{t+h} | \mathcal{F}_t], \quad V_h \equiv \text{Var}(Y_{t+h} | \mathcal{F}_t). \quad (1)$$

定理 1 (锐条件平方风险下界与超额风险正交分解). 对于任意预测规则 $\delta_h \in \mathcal{D}_t$ ，平方损失下的条件预测风险恒成立严格代数正交分解：

$$\mathcal{R}_h(\delta_h | \mathcal{F}_t) \equiv \mathbb{E}[(Y_{t+h} - \delta_h)^2 | \mathcal{F}_t] = V_h + (m_h - \delta_h)^2. \quad (2)$$

由此，条件均值预测器 $\delta_h^* = m_h$ 在 L^2 空间几乎处处（ $\mathbb{P}$ -a.s.）是唯一达到最小条件风险的最优预测器，其达到的下限恰为系统的不可约方差下界： $\inf_{\delta \in \mathcal{D}_t} \mathcal{R}_h(\delta | \mathcal{F}_t) = V_h$ 。任何经验预测器的超额风险严格非负且等于其平方偏差 $(m_h - \delta_h)^2 \geq 0$ 。

引理 1 (微观 Galton–Watson 分支过程的两阶矩递推). 设个体子代分布满足期望 $\mathbb{E}[\xi] = R$, 方差 $\text{Var}(\xi) = \sigma^2 = R + R^2/k_{ind}$. 预测原点初始感染人数 $Z_0 = I_0$. 则第 h 代累计发病规模的均值与方差满足严格解析递推:

$$\mathbb{E}[Z_h] = I_0 R^h, \quad \text{Var}(Z_h) = \begin{cases} I_0 \sigma^2 R^{h-1} \frac{R^h - 1}{R - 1}, & R \neq 1, \\ I_0 h \sigma^2, & R = 1. \end{cases} \quad (3)$$

引理 2 (微观相对方差饱和界与信息可达性). 在超临界传播 ($R > 1$) 下, 个体分支过程的相对方差 (变异系数平方 $CV_{micro}^2(h)$) 随提前期 h 单调递增并有界饱和于饱和常数界:

$$CV_{micro}^2(h) = \frac{\text{Var}(Z_h)}{(\mathbb{E}[Z_h])^2} = \frac{(1 + R/k_{ind})(1 - R^{-h})}{I_0(R - 1)} \xrightarrow{h \rightarrow \infty} CV_{\infty}^2 \equiv \frac{1 + R/k_{ind}}{I_0(R - 1)}. \quad (4)$$

2.2 宏观负二项更新模型的精确有限步方差闭式与机理边界

在周度宏观监测尺度上, 疾病传播序列在离散时间步下满足条件负二项更新分布 $Z_t | \mathcal{F}_{t-1} \sim \text{NB}(R_{\text{周}} Z_{t-1}, k_{agg})$. 记周度乘子 $R \equiv R_{\text{周}}$, 初始发病水平 $Z_0 = I_0$. 从连续代间隔分布 (Generation Interval Distribution $w(u)$) 的经典卷积更新方程 (Renewal Equation) 向周度离散模型过渡时, 该更新结构对应于代间隔时间分布粗粒化点质量近似 (或等价于 Gamma 分布形状参数 $\alpha \rightarrow \infty$ 的方差下限极限), 反映了周聚合统计下最小内在时序波动。同时, 本模型采用固定离散度 NB2 结构 (条件方差包含均值平方项 μ^2/k_{agg}), 这与宏观准泊松 (Quasi-Poisson, 方差呈线性放大的 NB1 结构) 在方差累积动力学上存在根本差异: NB1 在超临界下相对方差渐近收敛饱和, 而 NB2 结构内生导致了了几何发散项 $[(1 + 1/k_{agg})^h - 1]$, 是刻画现实异质性聚集爆发最严格的刚性方差下界。

定理 2 (固定离散度宏观负二项更新模型的精确有限步方差闭式). 在逐代独立更新的宏观负二项 (NB2) 聚合模型下, 条件方差满足一阶差分递推 $V_{t+1} = qV_t + I_0 R^{t+1} + \frac{I_0^2 R^{2t+2}}{k_{agg}}$, 其中 $q \equiv R^2(1 + 1/k_{agg})$. 对于任意整数提前期 $h \geq 1$, 该递推方程具有精确有限步方差闭式解:

$$V_h = I_0 R \frac{q^h - R^h}{q - R} + I_0^2 (q^h - R^{2h}), \quad (5)$$

其相对均方误差 (变异系数平方 $CV_{macro}^2(h)$) 严格等于:

$$CV_{macro}^2(h) \equiv \frac{V_h}{(I_0 R^h)^2} = \frac{R}{I_0} \cdot \frac{q^h - R^h}{R^{2h}(q - R)} + \left[\left(1 + \frac{1}{k_{agg}}\right)^h - 1 \right]. \quad (6)$$

引理 3 (参数不确定性的对数正态放大律). 设参数点估计满足大样本渐近正态性 $\log \hat{R} \sim \mathcal{N}(\log R, s^2)$. 采用自然代入式点预测 $\hat{Z}_h = I_0 \hat{R}^h$, 由对数正态矩展开, 参数外推误差导致的相对均方误差贡献项 $P_{exact}(h)$ 具有严格解析闭式:

$$P_{exact}(h; s) \equiv \frac{\mathbb{E}[(I_0 \hat{R}^h - I_0 R^h)^2]}{(I_0 R^h)^2} = \exp(2h^2 s^2) - 2 \exp(\frac{1}{2} h^2 s^2) + 1. \quad (7)$$

其领先阶二次项展开为 $P_{quad}(h; s) = (hs)^2$.




图 1: 传染病传播动力学与预测视界理论推导原理图。展示双源随机性动力学机制输入（内在动力学分支过程方差下界与外在参数估计误差几何放大）、预测相对均方误差正交分解（定理 1 与定理 2）以及由此导出的条件机制预测视界上限 h^* 闭式解与关键机理推论（近临界慢化塌缩、Fisher 信息界辨识约束与实测代数记账）。

2.3 机制预测视界映射与辨识信息界

定理 3 (负二项似然下的 Fisher 信息量与 Cramér–Rao 识别下限). 在负二项分支分布似然模型下, 基本再生数 R 的样本 Fisher 信息量满足 $\mathcal{I}_N(R, k_{\text{ind}}) = \frac{Nk_{\text{ind}}}{R(R+k_{\text{ind}})}$, 其无偏估计量的 Cramér–Rao 理论界为 $\text{Var}(\hat{R}) \geq \mathcal{I}_N^{-1} = \frac{R(1+R/k_{\text{ind}})}{N}$. 单侧检验下使估计相对标准误低于 ε 的理想有效样本量门槛为 $N \geq O(\varepsilon^{-2})$.

定理 4 (机制预测视界映射与解析闭式近似). 在条件正交假定下, 预测总相对均方误差加性分解为 $\text{RelMSE}(h) = \text{CV}_{\text{macro}}^2(h) + P_{\text{exact}}(h)$. 机制预测视界连续阈值根定义为:

$$h_{\text{cont}}^* \equiv \sup \{h \geq 0 \mid \text{RelMSE}(h) \leq \tau^2\}. \quad (8)$$

在连续时间与大样本领先阶逼近下, 超临界且 $\tau^2 > \text{CV}_{\infty}^2$ 时, 机制预测视界 h^* 满足领先阶闭

式近似：

$$h^* \approx \frac{\sqrt{\tau^2 - CV_\infty^2}}{S_{\text{周}}} \quad (9)$$

3 数值复核与基准算法实现检验

为验证理论公式的自洽性，设计了覆盖 $R \in [0.8, 3.0]$ 、 $k \in [0.1, 5.0]$ 、 $I_0 \in [10, 1000]$ 、 $h \in \{1, \dots, 12\}$ 的大规模蒙特卡洛随机模拟（20,000 条独立轨迹，固定随机数种子）。




图 2：微观分支方差饱和与宏观 NB2 更新方差几何增长的双尺度蒙特卡洛验证。(a) 微观个体分支过程的相对方差饱和；(b) 宏观 NB2 聚合更新模型的方差几何增长，实线为定理 2 闭式解，散点为 20,000 条模拟轨迹经验值，两者高度吻合。

数值实验证实（图 2）：(1) 宏观 NB2 相对方差模拟经验值与定理 2 闭式解的相对偏差稳定在 0.5%–1.5% 之内，证实了几何累积主项 $[(1 + 1/k_{\text{agg}})^h - 1]$ 的正确性；而忽略该项的一阶近似 h/k_{agg} 在 $h = 12$ 时低估达 25.5%；(2) 在全网格上经验与理论 ReIMSE 均随 h 严格单调递增，证实了单调性定理；(3) 极大似然估计的经验方差与 Cramér–Rao 理论界之比在 0.992–1.011 之间，完全通过大规模数值复核。

4 真实数据实证（上）：微观传播链与州级住院面板

4.1 监测数据来源与微观接触链验证

微观证据基于两组权威公开接触追踪数据集：中国香港早期 COVID-19 传播网络（本土聚集性子队列 $N = 355$ 与全队列 $N = 1,038$ ）[27]，以及几内亚科纳克里埃博拉传播网络（ $N = 152$ ）[28]。对各数据集实施极大似然拟合，结果见表 2 与图 3。

表 2：微观传播链层的子代分布极大似然拟合与信息论下界检验

数据集	N	$\hat{R}$	95% CI	$\hat{k}$	95% CI	经验 CV^2	理论 CV^2	ΔAIC	自助/CRB	拟合优度 p
香港 COVID-19（本地）	355	0.473	0.37–0.58	0.434	0.30–0.71	5.46	4.42	93.9	1.059	0.2525
香港 COVID-19（全体）	1038	0.162	0.13–0.20	0.111	0.08–0.16	17.85	15.19	223.4	1.027	0.4431
几内亚埃博拉 2014	152	0.954	0.61–1.36	0.182	0.12–0.30	6.41	6.56	244.0	0.984	0.9509

实证表明：负二项模型相较 Poisson 获得压倒性拟合优势（ ΔAIC 达 93.9–244.0），实测离散参数低至 $\hat{k} = 0.111$ –0.434，证实强异质性超级传播是个体层面的客观规律；参数化 Bootstrap 方差与 CRB 之比为 0.984–1.059，在抽样误差内与理论下界精确吻合。




图 3: 个体传播链子代分布的负二项拟合与 Cramér–Rao 理论界验证。负二项模型显著优于 Poisson 对照 ($\Delta AIC = 93.9\text{--}244.0$), Bootstrap 方差与 Cramér–Rao 界比值为 0.984–1.059, 确立了负二项设定的经验合法性。

4.2 州级面板层: NB2 机制视界分布与聚合效应

将宏观 NB2 方差方程应用于覆盖美国最多 51 个州级辖区的住院面板, 涵盖 COVID-19 (Delta、Omicron、JN.1)、季节性流感 (2022–23、2024–25) 与 RSV (2024–25、2025–26) 共七个流行阶段。采用 5 周滑动窗口对数线性回归估计周度乘子 R 与标准误 s , 对数差分二阶矩法估计 k_{agg} 。各阶段纳入满足最低发病门槛 (累计 ≥ 50 例且每周非零) 的辖区 (26–51 个)。

表 3: 州级面板各阶段动力学参数与代入式 NB2 模型内机制视界分布 (中位数与四分位距)

阶段	$n_{州}$	$R_{周}$	中位数 [IQR]	$s_{周}$	中位数	k_{agg}	中位数	I_0	中位数	$h_{周}^*$	中位数 [IQR]	国家级 $h_{周}^*$
COVID-19 Delta 暴发期	50	1.271	[1.206, 1.358]	0.0373	56.6	297	7.1	[3.4, 12.1]	17.0			
COVID-19 Omicron 达峰期	51	1.099	[0.971, 1.253]	0.0482	21.0	758	4.0	[2.5, 8.0]	3.9			
COVID-19 JN.1 流行期	51	1.044	[0.997, 1.097]	0.0447	29.5	391	5.0	[3.8, 7.8]	7.0			
流感 2022–23 暴发早期	38	1.554	[1.401, 1.875]	0.0726	11.2	55	2.2	[1.0, 4.6]	6.3			
流感 2024–25 流行季	45	1.605	[1.493, 1.754]	0.0637	17.4	96	2.6	[1.8, 7.1]	11.1			
RSV 2024–25 流行季	34	1.347	[1.277, 1.419]	0.0433	39.8	76	5.8	[2.6, 10.1]	$\geq 20^\dagger$			
RSV 2025–26 流行季	26	1.302	[1.224, 1.358]	0.0546	23.7	38	3.9	[1.4, 9.1]	$\geq 20^\dagger$			

注: 全部参数在周度时钟上定义: $R_{周} = \exp(b_{week})$ 为周度增长乘子, $s_{周} = SE(b_{week})$ 为对数标准误 ($df = 3$); k_{agg} 为对数差分二阶矩估计; I_0 为窗口周度均值; $h_{周}^*$ 为代入式 NB2 模型内全方差临界方程 ($\tau = 0.5$) 数值求得的连续阈值根; 末列为 51 个辖区聚合的国家级序列对应值。† 标注表示国家级测算值超出单季 20 周跨度 (记作 ≥ 20)。

实证测算表明 (表 3 与图 4):

- 机制视界取值区间:** 5 周基准窗口下代入式 NB2 机制视界跨州中位数落在 **2.2–7.1 周** (Delta 为 7.1 周, Omicron 为 4.0 周 (国家级聚合为 3.9 周), JN.1 为 5.0 周, 两季流感为 2.2 与 2.6 周, 两季 RSV 为 5.8 与 3.9 周)。多窗口 (5/6/8/10 周) 极值包络覆盖 1.52–8.07 周。
- 空间平滑与尺度抬升:** 在七个阶段中, 有六个阶段的州级中位数显著低于国家级聚合视界 (Delta 7.1 周对 17.0 周, 流感 22–23 为 2.2 对 6.3 周, RSV 24–25 为 5.8 对 ≥ 20 周)。空间聚合显著平抑了局部离散度并压低估计误差, 从而抬高了聚合层面的机制视界。
- 过程方差的主导地位:** 在视界临界工作点处, 宏观过程方差占比 $CV_{macro}^2(h^*)/\tau^2$ 跨州中位数普遍高达 **0.73–0.89** (图 4b), 证实宏观离散度是制约预警时效的首要内在统计瓶颈。




图 4: NB2 模型内机制视界的州级分布、国家级聚合值对比与方差主导比率。(a) 各流行阶段州级辖区机制视界 h^* 的箱线图与散点分布, 红色菱形为国家级视界; (b) 视界临界点处的宏观过程方差主导比率 $CV_{\text{macro}}^2(h^*)/\tau^2$, 跨阶段中位数达 0.73–0.89, 表明宏观离散度构成核心刚性约束。

4.3 描述性误差记账与模型–观测代数差额

为考察理论机制方差是否能解释现实预测误差, 构建三项描述性代数记账恒等式:

$$\text{RelMSE}_{\text{obs}}(h) = CV_{\text{macro}}^2(h) + P_{\text{quad}}(h) + \mathcal{E}_{\text{res}}(h), \quad (10)$$

其中 $\text{RelMSE}_{\text{obs}}(h)$ 为各州在伪实时滚动预测中实测的总相对均方误差, $\mathcal{E}_{\text{res}}(h)$ 为模型–观测代数差额 (Model-Observation Algebraic Discrepancy)。

记账结果 (表 4) 揭示了至关重要的科学事实: 在全部 21 个阶段–步长配置中, 模型–观测代数差额跨州中位数占比的中位数为 55.0% ($h = 1$ 为 45.4%, 随步长延伸上升至 $h = 4$ 的 78.6%); 在 21 个配置中有 20 个配置的跨州中位数差额严格为正 (代数差额为正的州占比介于 49% 与 94% 之间)。显式计算的宏观方差与外推项在绝大多数情境下均不足以覆盖实测误差, 差额项综合吸收了非平稳漂移、行为自适应与医疗报告回填。这一事实确凿证明: 理论机制视界应定位为基于动力学生成假设的“现实预警时效的宽松经验参考外包络”, 而非现实业务系统的紧致预测极限。

5 真实数据实证 (下): 版本化外部预测枢纽审计

5.1 FluSight 审计协议与完整评分面板

为避免后验修改与报告偏差争议, 外部审计全面对接美国 CDC 流感协同预测枢纽 (CDC FluSight Forecast Hub) [4]。锁定连续三个完整流行季的官方发行版本: 2023–24 赛季 (v1.0.0)、2024–25 赛季 (v1.1.0) 与 2025–26 赛季 (v1.2.0), 共固化 204 个原始输入文件 (SHA-256 逐文件核验固化于 data/input_hashes.json)。

评估实施**严格四方共同单元配对过滤** (原点、地点、提前期与终报真值同时存在于官方集成 Hub-ensemble、官方基线 Hub-baseline、受控代入式机制预测器与 CDC 终报真值), 确保同一赛季三模型共享完全相同的样本量 n 。机制预测器基于原点因果截断的终报数据拟合, 剥离了初报延迟噪声, 在受控最优数据条件下作为诊断基准。基于 23 个标准分位数计算加权区间评分 (WIS)、经验覆盖率与区间名义宽度 (表 5 与图 5)。

审计结果显示三大跨赛季稳健特征: (1) **集成的持续技能优势**: 在所有赛季与提前期上, Hub 集成模型的 WIS 均显著优于基线与机制预测器 ($h = 1$ 时 v1.0.0 为 34.00 对 45.68 对

表 4: 两项显式模型分量与模型–观测代数差额的描述性误差记账州级分解

阶段	$h_{\text{周}}$	$n_{\text{州}}$	$\text{RelMSE}_{\text{obs}}$	CV^2	P_{quad}	代数差额占比 (IQR)	为正占比
COVID-19 Delta 暴发期	1	50	626.89	250.12	13.90	60.6% [25.3, 78.6]	86%
	2	50	3253.83	498.22	55.60	85.7% [56.5, 92.2]	88%
	4	50	34743.97	981.55	222.41	95.8% [87.2, 98.3]	94%
COVID-19 Omicron 达峰期	1	51	816.84	478.54	23.20	32.0% [16.4, 48.4]	92%
	2	51	2677.91	979.03	92.78	67.6% [54.7, 80.2]	94%
	4	51	8165.24	2050.93	371.12	78.6% [48.8, 90.2]	90%
COVID-19 JN.1 流行期	1	51	332.34	359.13	19.97	-0.0% [-36.0, 18.2]	49%
	2	51	1014.61	730.69	79.89	18.6% [0.2, 36.5]	75%
	4	51	2602.15	1512.93	319.57	31.1% [5.8, 55.9]	78%
流感 2022–23 暴发早期	1	38	1828.33	1007.97	52.64	45.4% [24.0, 72.9]	87%
	2	38	5589.09	2085.76	210.57	63.9% [16.8, 90.8]	84%
	4	38	23754.52	4478.46	842.28	81.5% [42.1, 95.9]	87%
流感 2024–25 流行季	1	45	1458.86	826.83	40.52	55.0% [24.4, 72.4]	84%
	2	45	6582.44	1702.11	162.07	76.0% [60.4, 86.8]	89%
	4	45	20689.32	3632.76	648.28	86.9% [68.3, 97.5]	89%
RSV 2024–25 流行季	1	34	696.45	376.31	18.79	47.9% [-10.7, 72.8]	74%
	2	34	1589.16	683.53	75.14	48.8% [14.9, 75.6]	76%
	4	34	3872.38	1248.42	300.58	59.5% [30.6, 76.7]	79%
RSV 2025–26 流行季	1	26	760.14	622.66	30.33	15.2% [-1.1, 53.2]	69%
	2	26	1253.19	1153.66	121.31	10.8% [-117.0, 41.8]	58%
	4	26	3019.88	2236.50	485.23	13.1% [-50.3, 64.2]	54%

注：每行统计通过门槛的州级辖区；各分量列报跨州中位数（单位 10^{-4} ）；代数差额占比列为跨州中位数及四分位距，末列为代数差额为正的州占比。实测总误差由滚动原点计算，代数差额按 $\mathcal{E}_{\text{res}} = \text{RelMSE}_{\text{obs}} - (\text{CV}^2_{\text{macro}} + P_{\text{quad}})$ 吸收定义。

表 5: CDC FluSight 外部审计评分面板：三个锁定历史赛季 ($h = 1$ 周，严格四方交集)

赛季	模型	n	WIS	覆盖 50%	覆盖 80%	覆盖 95%	宽 95%	PIT
v1.0.0 (2023–24)	Hub 集成	1,337	34.00	0.524	0.794	0.933	231.8	0.568
	官方基线	1,337	45.68	0.265	0.606	0.895	256.5	0.500
	机制预测器	1,337	59.94	0.214	0.384	0.554	142.1	0.506
v1.1.0 (2024–25)	Hub 集成	1,315	85.27	0.551	0.739	0.837	382.1	0.605
	官方基线	1,315	125.11	0.317	0.552	0.742	376.4	0.479
	机制预测器	1,315	170.88	0.128	0.269	0.405	329.0	0.381
v1.2.0 (2025–26)	Hub 集成	1,376	60.24	0.516	0.780	0.905	315.1	0.559
	官方基线	1,376	90.57	0.438	0.738	0.869	407.1	0.486
	机制预测器	1,376	116.72	0.201	0.378	0.531	269.7	0.363

注：评估基于严格四方交集单元，同赛季三模型 n 完全相同；WIS 为 23 分位数加权区间评分；覆盖率为标称区间命中率；95% 区间宽为绝对病人数尺度；PIT 为分位数插值近似随机化 PIT 均值。




图 5: CDC FluSight 三个连续赛季外部审计与峰值相对位置分层校准特征。(a) 加权区间评分 (WIS) 随提前期 h 的衰减轨迹; (b) 各阶段经验 95% 预测区间覆盖率 ($h = 1$), 多模型在峰前期普遍欠覆盖; (c) $h = 1$ 时各模型相对集成的超额 WIS 及配对 95% Bootstrap 置信区间。

59.94; v1.1.0 为 85.27 对 125.11 对 170.88; v1.2.0 为 60.24 对 90.57 对 116.72), 配对差的 HHS 大区整群聚类 95% 自助区间严格不跨零; (2) 纯机制基准预测器的严重经验欠覆盖: 代入式机制预测器标称 95% 区间的实测覆盖率仅为 0.405–0.554, 其预测区间名义宽度系统性比基线窄 12.6%–44.6%, 表明静态机制方差严重低估了现实宏观波动; (3) 非对称尾部惩罚: 机制预测器的 PIT 均值系统偏离 0.50 (v1.1.0 与 v1.2.0 为 0.381 与 0.363), 反映出明显的向上偏差与凸性尾部惩罚放大。

5.2 峰前期校准特征与 COVIDhub 对照

依据各辖区完整流行季的全局住院峰值日期进行事后分层: 峰前 > 7 天 (Pre-peak)、峰值 ± 7 天 (Peak window) 与峰后 > 7 天 (Post-peak), 结果见表 6。

表 6: CDC FluSight 外部审计按全局峰值相对位置分层的校准特征 ($h = 1$ 周, 严格四方交集)

赛季	峰值相对位置阶段	n	WIS (括号内为标称 95% 区间实测覆盖率)		
			Hub 集成	官方基线	机制预测器
v1.0.0 (2023–24)	峰前期 (Pre-peak)	108	42.79 (0.852)	61.21 (0.759)	76.35 (0.370)
	峰值窗口 (Peak window)	36	138.73 (0.667)	176.13 (0.417)	181.28 (0.417)
	峰后期 (Post-peak)	1,193	30.05 (0.948)	40.34 (0.922)	54.79 (0.575)
v1.1.0 (2024–25)	峰前期 (Pre-peak)	343	176.51 (0.589)	207.73 (0.539)	232.73 (0.385)
	峰值窗口 (Peak window)	132	206.84 (0.674)	266.55 (0.386)	225.78 (0.606)
	峰后期 (Post-peak)	840	28.91 (0.964)	69.14 (0.881)	137.00 (0.381)
v1.2.0 (2025–26)	峰前期 (Pre-peak)	43	160.93 (0.419)	240.78 (0.488)	276.93 (0.140)
	峰值窗口 (Peak window)	32	259.91 (0.719)	447.34 (0.219)	424.55 (0.281)
	峰后期 (Post-peak)	1,301	52.00 (0.925)	76.83 (0.898)	103.85 (0.550)

注: 阶段划分依据各州级辖区完整流行季全局峰值日期 (事后分层); 括号内为标称 95% 预测区间的实测经验覆盖率。本表汇总 $h = 1$ 。

分层审计给出了决定性的实证发现: 在疫情峰后期, Hub 集成模型的 95% 区间经验覆盖率达到 0.925–0.964, 接近标称水平; 官方基线为 0.881–0.922。然而, 一旦进入疫情峰前期,

各模型的经验覆盖率均发生骤降：Hub 集成在三赛季分别降至 **0.852**、**0.589** 和 **0.419**，官方基线降至 0.759、0.539 和 0.488，受控机制预测器更骤降至 **0.370**、**0.385** 和 **0.140**。图 6 的 COVIDhub 历史对照进一步证实该规律在新冠 Delta 与 Omicron 爆发期同样存在（12 个原点中有 11 个在 1–2 周内失去相对技能）。尤为关键的理论与实证事实在于：机制预测器（Mechanism Predictor）在构建时享有完全剔除初报延迟与数据回填修订的“终报黄金真值”（Ground Truth Final Data），即完全剥离了现实数据流中的初报噪声，然而其在流行峰前期的 95% 经验覆盖率依然被急剧击穿（从峰后期的 0.90+ 骤降至 0.140–0.385）。这一严密受控证据无可辩驳地证实：峰前期的校准骤降并非单纯由公共卫生统计回填或工程数据延迟等外部数据瑕疵所致，而是源于真实传染病系统在指数暴发期所固有的强非平稳传播动力学跃迁、跨尺度行为自适应反馈以及结构变点的本质不可预测性。




图 6: COVIDhub-ensemble 州级相对技能变化与原始尺度 WIS 上升。(a) 跨州中位数平方误差比率，12 个原点中有 11 个在 1–2 周内穿透平价线；(b) 原始计数尺度下的 WIS 随提前期上升。

6 讨论与公共卫生启示

6.1 公共卫生决策分级映射与运筹转化

公共卫生决策对前瞻窗口与容忍度具有分级需求。当面临重症 ICU 扩容等高成本刚性决策时 ($\tau = 0.20$)，州级中位 NB2 机制视界收缩至 0.4–1.5 周 (Omicron 为 0.8 周)，提示绝不宜将中远期点预测单独作为刚性决策依据；常态物资调配 ($\tau = 0.35$) 与社会面准备 ($\tau = 0.50$) 阶段拓展至 1.2–4.1 周；放宽至 $\tau = 0.70$ 时拓宽至 3.9–11.0 周。实测业务时效约为主观机制视界的 $1/4 \sim 1/1.1$ ，应急调度需预留充足安全余量。

从数学极限向应急运筹转化需建立非对称损失风险控制边界 [29]。特别是，当机制预测视界小于关键公共卫生干预的前置期 (Lead Time) 时 (例如重症 ICU 扩容与医护人员跨区域梯次支援通常需要 1–2 周的前置准备窗口，但在严格误差容忍 $\tau = 0.20$ 下实测视界仅为 0.4–1.5 周)，公共卫生指挥机构必须实现从“依赖点预测精确调度”向“最坏极端情景 (Worst-Case Scenario) 鲁棒防御策略”的范式切换：(1) **预置弹性冗余与触发式前置干预**：以历史最大暴发增速的分位数上界设定动态应急床位冗余，而非按单条预测轨迹均值紧凑备勤；(2) **非对称损失函数嵌入**：由于低估峰值引发医疗挤兑的社会与生命代价远超适度超额备勤的物力沉没成本，优化目标应内生加权右尾超额风险；(3) **有效预警提前量与监测时滞补偿**：实际净预警窗口满足 $\Delta t_{\text{alert}} = h^* - t_{\text{detect}}$ ，必须通过高灵敏度前哨监测点压缩检测延迟 t_{detect} ，为防御动作争取应急响应时间。在健康公平性层面，欠发达地区监测网络稀疏会导致有效样本量

$\rho_{\text{low}} \ll \rho_0$ ，在参数敏感区其理论视界呈平方根标度衰减 $h_{\text{low}}^*/h_0^* \approx \sqrt{\rho_{\text{low}}/\rho_0}$ ；而在过程方差占主导（73%–89%）的实际工况下，报告率减半往往直接击穿容忍阈值，致使有效视界完全归零。因此，资源配置必须向薄弱地区倾斜常态化监测网络。

6.2 研究局限性

本文的适用边界体现在：(1) 代数差额中位占比 55.0% 综合反映现实业务扰动，非因果正交分解；(2) 宏观方差结构是首要敏感性来源，由 NB2 切换为 Poisson 或 NB1 后视界延长 1.1–2.6 倍，读者应将主数值理解为“固定 NB2 条件基准”；(3) 5–10 周推断窗口变动带来 –48.7% 至 +44.6% 浮动，体现了方差与平稳性的统计权衡；(4) 峰前期事后分层基于全局峰值，不宜归结为单一因果效应；(5) 理论推导未耦合易感耗竭非线性负反馈（SIR 类），适用于流行早期上升阶段。

7 结论

本文系统构建了区分理论条件风险下界、NB2 模型内过程方差、代入式预测风险与现实业务误差的分层基准体系。理论上确立了平方损失下的锐条件方差下界，推导了宏观 NB2 更新模型的精确有限步方差闭式。实证上依托微观传播链、51 州面板与 CDC FluSight 三赛季外部审计证实：(1) 负二项模型显著优于 Poisson (ΔAIC 达 93.9–244.0)；(2) 州级中位机制视界为 2.2–7.1 周（多窗口包络 1.52–8.07 周）；(3) 误差记账表明机制分量不足以覆盖实测误差（代数差额跨州中位占比 55.0%）；(4) 外部审计揭示机制预测器在终报条件下标称 95% 覆盖率仅 0.405–0.554，且峰前期各模型普遍发生校准骤降（覆盖率降至 0.140–0.419）。这一结论证实机制视界构成了现实预警时效的宽松经验参考外包络，为公共卫生应急调度与下一代具备动态方差感知能力的预测系统提供了严谨的基准参照。

附录：核心定理证明要点与全景检索

针对全文核心数理结论，正文呈现结论与机理直觉，逐行展开的详尽代数运算系统收录于独立推导手册《过离散传染病更新模型的条件预测风险与视界》（*Conditional Risk, Exact Macro Variance, and Forecast Horizons*）。下表列出核心定理对应索引：

表 7：核心定理数理推导索引目录

结论编号与名称	核心动力学 / 统计内涵	正文位置	核心数理工具与关键证明步骤	推导手册出处
定理 1 锐条件方差下界	平方损失下不可约误差极限	式 (2)	$L^2(\Omega, \mathcal{F}_t, \mathbb{P})$ 条件期望正交投影，交叉项几乎处处为零	手册 §3 条件风险恒等式
引理 1 分支过程两阶矩	微观发病均值与方差递推	式 (3)	全期望与全方差分解，一阶非齐次差分方程伸缩求和	手册 §2.2 个体层 GW 模型
引理 2 相对方差饱和和界	微观个体相对方差渐近饱和	式 (4)	矩比值极限分析，发散与收敛阶数匹配	手册 §2.2 个体层全代方差
引理 3 对数正态放大	参数外推超额均方误差	式 (7)	对数正态分布矩母函数展开，严格二阶泰勒展开	手册 §4.1 参数外推放大项
定理 4 机制视界映射	视界临界方程与闭式近似	式 (8)	连续单调方程求根，超临界领先阶平衡展开	手册 §4.2 视界封闭近似
定理 2 宏观 NB2 方差	宏观更新模型精确有限步方差闭式	式 (5)	一阶非齐次差分方程特征根展开与裂项求和	手册 §2.3 宏观更新模型

参考文献

[1] Nicholas G Reich et al. A collaborative multiyear, multimodel assessment of seasonal influenza forecasting in the United States. *Proceedings of the National Academy of Sciences*, 116:3146–3154, 2019. doi: 10.1073/pnas.1812594116.

[2] Samuel V Scarpino and Giovanni Petri. On the predictability of infectious disease outbreaks. *Nature Communications*, 10:898, 2019. doi: 10.1038/s41467-019-08616-0.

[3] Craig J McGowan et al. Collaborative efforts to forecast seasonal influenza in the United States, 2015–2016. *Scientific Reports*, 9:683, 2019. doi: 10.1038/s41598-018-36361-9.

[4] Sarabeth M. Mathis et al. Evaluation of FluSight influenza forecasting in the 2021–22 and 2022–23 seasons with a new target laboratory-confirmed influenza hospitalizations. *Nature Communications*, 15:6289, 2024. doi: 10.1038/s41467-024-50601-9.

[5] Cécile Viboud, Kaiyuan Sun, Robert Gaffey, Marco Ajelli, Laura Fumanelli, Stefano Merler, Qian Zhang, Gerardo Chowell, Lone Simonsen, and Alessandro Vespignani. The RAPIDD ebola forecasting challenge: Synthesis and lessons learnt. *Epidemics*, 22:13–21, 2018. doi: 10.1016/j.epidem.2017.08.002.

[6] Michael A Johansson et al. An open challenge to advance probabilistic forecasting for dengue epidemics. *Proceedings of the National Academy of Sciences*, 116:24268–24274, 2019. doi: 10.1073/pnas.1909865116.

[7] Estee Y Cramer et al. Evaluation of individual and ensemble probabilistic forecasts of COVID-19 mortality in the US. *Proceedings of the National Academy of Sciences*, 119:e2113561119, 2022. doi: 10.1073/pnas.2113561119.

[8] Katharine Sherratt, Hugo Gruson, Rilind Grah, Helen Johnson, Rene Niehus, Bastian Prasse, Frank Sandmann, Jannik Deuschel, et al. Predictive performance of multi-model ensemble forecasts of COVID-19 across European nations. *eLife*, 12:e81916, 2023. doi: 10.7554/eLife.81916.

- [9] Ehsan Suez and Spencer J. Fox. Basic baseline model design choices can substantially influence performance in collaborative forecast hubs. *medRxiv*, 2026. doi: 10.64898/2026.03.18.26348748.
- [10] V K Lopez, E Y Cramer, R Pagano, J M Drake, E B O’Dea, et al. Challenges of COVID-19 case forecasting in the US, 2020–2021. *PLOS Computational Biology*, 20(5):e1011200, 2024. doi: 10.1371/journal.pcbi.1011200.
- [11] Omar Melikechi, Alexander L Young, Tao Tang, Trevor Bowman, David Dunson, and James Johndrow. Limits of epidemic prediction using SIR models. *Journal of Mathematical Biology*, 85(4):36, 2022. doi: 10.1007/s00285-022-01804-5.
- [12] Aaron A King, Matthieu Domenech de Cellès, Felicia G G Magpantay, and Pejman Rohani. Avoidable errors in the modelling of outbreaks of emerging pathogens, with special reference to Ebola. *Proceedings of the Royal Society B: Biological Sciences*, 282(1806):20150347, 2015. doi: 10.1098/rspb.2015.0347.
- [13] Krishna B Athreya and Peter E Ney. *Branching Processes*. Springer, Berlin, 1972.
- [14] James O Lloyd-Smith, Sebastian J Schreiber, P Ekkehard Kopp, and Wayne M Getz. Superspreading and the effect of individual variation on disease emergence. *Nature*, 438:355–359, 2005. doi: 10.1038/nature04153.
- [15] Anne Cori, Neil M Ferguson, Christophe Fraser, and Simon Cauchemez. A new framework and software to estimate time-varying reproduction numbers during epidemics. *American Journal of Epidemiology*, 178:1505–1512, 2013. doi: 10.1093/aje/kwt133.
- [16] Katelyn M Gostic et al. Practical considerations for measuring the effective reproductive number, R_t . *PLOS Computational Biology*, 16:e1008409, 2020. doi: 10.1371/journal.pcbi.1008409.
- [17] Kris V Parag and Christl A Donnelly. Using information theory to optimise epidemic models for real-time prediction and estimation. *PLOS Computational Biology*, 16(7):e1007990, 2020. doi: 10.1371/journal.pcbi.1007990.
- [18] Kris V Parag and Christl A Donnelly. Fundamental limits on inferring epidemic resurgence in real time using effective reproduction numbers. *PLOS Computational Biology*, 18(4):e1010004, 2022. doi: 10.1371/journal.pcbi.1010004.
- [19] Kris V Parag, Christl A Donnelly, and Alexander E Zarebski. Quantifying the information in noisy epidemic curves. *Nature Computational Science*, 2(9):584–594, 2022. doi: 10.1038/s43588-022-00313-1.
- [20] Leonhard Held, Sebastian Meyer, and Johannes Bracher. A statistical framework for the analysis of multivariate infectious disease surveillance data. *Statistics in Medicine*, 36(22):3443–3460, 2017. doi: 10.1002/sim.7363.
- [21] John M Drake. Limits to forecasting precision for outbreaks of directly transmitted diseases. *PLOS Medicine*, 3(1):e3, 2006. doi: 10.1371/journal.pmed.0030003.
- [22] Owen L. Petchey, Mikael Pontarp, Thomas M. Massie, et al. The ecological forecast horizon, and examples of its uses and determinants. *Ecology Letters*, 18(7):597–611, 2015. doi: 10.1111/ele.12443.

- [23] Marieke Wesselkamp, Jakob Albrecht, Ewan Pinnington, William J. Castillo, Florian Pappenberger, and Carsten F. Dormann. The ecological forecast limit revisited: Potential, absolute and relative system predictability. *Methods in Ecology and Evolution*, 16:1521–1541, 2025. doi: 10.1111/2041-210x.70049.
- [24] Claudio Bozzuto and Anthony R Ives. Differences in COVID-19 cyclicity and predictability among U.S. counties and states reflect the effectiveness of protective measures. *Scientific Reports*, 13:14277, 2023. doi: 10.1038/s41598-023-40990-0.
- [25] Matthew J Penn, Daniel J Laydon, Joseph Penn, et al. Intrinsic randomness in epidemic modelling beyond statistical uncertainty. *Communications Physics*, 6:146, 2023. doi: 10.1038/s42005-023-01265-2.
- [26] Johannes Bracher, Evan L Ray, Tilmann Gneiting, and Nicholas G Reich. Evaluating epidemic forecasts in an interval format. *PLOS Computational Biology*, 17:e1008618, 2021. doi: 10.1371/journal.pcbi.1008618.
- [27] Dillon C Adam, Peng Wu, Jessica Y Wong, Eric H Y Lau, Tim K Tsang, Simon Cauchemez, Gabriel M Leung, and Benjamin J Cowling. Clustering and superspreading potential of SARS-CoV-2 infections in Hong Kong. *Nature Medicine*, 26(11):1714–1719, 2020. doi: 10.1038/s41591-020-1092-0.
- [28] Ousmane Faye, Pierre-Yves Boëlle, Emmanuel Heleze, Oumar Faye, Cheikh Loucoubar, N’Faly Magassouba, Barré Soropogui, Sakoba Keita, Tata Gakou, El Hadji Ibrahima Bah, Lamine Koivogui, Amadou Alpha Sall, and Simon Cauchemez. Chains of transmission and control of Ebola virus disease in Conakry, Guinea, in 2014: an observational study. *The Lancet Infectious Diseases*, 15(3):320–326, 2015. doi: 10.1016/S1473-3099(14)71075-8.
- [29] Kris V Parag, Ben Lambert, Christl A Donnelly, and Sandor Beregi. Asymmetric limits on timely interventions from noisy epidemic data. *Communications Physics*, 8:450, 2025. doi: 10.1038/s42005-025-02358-w.